

Análisis Exploratorio de Datos con Pandas y Python

Sintaxis, operaciones frecuentes, y ejemplos

Índice

1. Objetivo y convenciones	8
2. Preparación del entorno	8
2.1. Instalación de bibliotecas	8
2.2. Importación de la librería	8
2.3. Consulta de versiones instaladas	8
2.4. Opciones de visualización de pandas	9
3. Carga y apertura de datos	9
3.1. Leer un archivo CSV	9
3.2. CSV con separador diferente	9
3.3. CSV con codificación específica	9
3.4. Seleccionar columnas al leer un CSV	10
3.5. Indicar tipos de datos durante la lectura	10
3.6. Interpretar fechas al cargar	10
3.7. Definir cadenas que representan valores faltantes	10
3.8. Decimales y separadores de miles	10
3.9. Omitir filas iniciales	10
3.10. Leer solamente las primeras filas	10
3.11. Leer archivos grandes por bloques	11
3.12. Leer Excel	11
3.13. Leer JSON	11
3.14. Leer Parquet	11
3.15. Leer datos desde el portapapeles	11
4. Inspección inicial del DataFrame	11
4.1. Mostrar el DataFrame	11
4.2. Primeras filas	12
4.3. Últimas filas	12
4.4. Muestra aleatoria	12
4.5. Número de filas y columnas	12
4.6. Número total de elementos	12
4.7. Nombres de columnas	12
4.8. Índice	12
4.9. Tipos de datos	13
4.10. Resumen estructural	13
4.11. Estadística descriptiva rápida	13
4.12. Cantidad de valores no nulos por columna	13

1. Objetivo y convenciones

Estos apuntes reúnen operaciones frecuentes para realizar **Análisis Exploratorio de Datos (EDA)** con Python y pandas.

Se incluyen ejemplos para carga y guardado de archivos, inspección, selección, filtrado, búsqueda, limpieza, tratamiento de cadenas, fechas, estadística descriptiva, agrupaciones, tablas dinámicas, detección de valores atípicos, correlaciones y visualización.

En la mayoría de los ejemplos se supone que el conjunto de datos se encuentra en un objeto llamado `df`.

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4
5 # Ejemplo de un DataFrame
6
7 df = pd.DataFrame({
8     "Nombre": ["Ana", "Luis", "Marta", "Pedro", "Sofia"],
9     "Edad": [21, 25, 23, 30, 27],
10    "Ciudad": ["Tampico", "Madero", "Tampico", "Altamira", "Madero"],
11    "Ingreso": [12500.0, 18000.0, 15200.0, 24000.0, 21000.0],
12    "Activo": [True, True, False, True, True],
13    "Fecha": ["2026-01-15", "2026-02-03", "2026-02-18", "2026-03-01", "2026-03-15"]
14 })
```

2. Preparación del entorno

2.1. Instalación de bibliotecas

Desde una terminal:

```
1 pip install pandas numpy matplotlib openpyxl pyarrow
```

En Jupyter Notebook o Google Colab puede utilizarse:

```
1 !pip install pandas numpy matplotlib openpyxl pyarrow
```

2.2. Importación de la librería

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
```

2.3. Consulta de versiones instaladas

```
1 print(pd.__version__)
2 print(np.__version__)
```

2.4. Opciones de visualización de pandas

```
1 # Mostrar mas filas
2 pd.set_option("display.max_rows", 200)
3
4 # Mostrar mas columnas
5 pd.set_option("display.max_columns", 100)
6
7 # Ancho maximo de una columna de texto
8 pd.set_option("display.max_colwidth", 120)
9
10 # Ancho total aproximado de la salida
11 pd.set_option("display.width", 160)
12
13 # Formato de numeros flotantes
14 pd.set_option("display.float_format", lambda x: f"{x:,.2f}")
```

Restablecer una opción:

```
1 pd.reset_option("display.max_rows")
2 pd.reset_option("display.float_format")
```

3. Carga y apertura de datos

3.1. Leer un archivo CSV

```
1 df = pd.read_csv("datos.csv")
```

3.2. CSV con separador diferente

```
1 # Punto y coma
2
3 df = pd.read_csv("datos.csv", sep=";")
4
5 # Tabulador
6
7 df = pd.read_csv("datos.tsv", sep="\t")
8
9 # Barra vertical
10
11 df = pd.read_csv("datos.txt", sep="|")
```

3.3. CSV con codificación específica

```
1 df = pd.read_csv("datos.csv", encoding="utf-8")
2
3 df = pd.read_csv("datos.csv", encoding="latin-1")
```

3.4. Seleccionar columnas al leer un CSV

```
1 df = pd.read_csv(  
2     "datos.csv",  
3     usecols=["Nombre", "Edad", "Ciudad", "Ingreso"]  
4 )
```

3.5. Indicar tipos de datos durante la lectura

```
1 df = pd.read_csv(  
2     "datos.csv",  
3     dtype={  
4         "Nombre": "string",  
5         "Ciudad": "string",  
6         "Edad": "Int64"  
7     }  
8 )
```

3.6. Interpretar fechas al cargar

```
1 df = pd.read_csv(  
2     "datos.csv",  
3     parse_dates=["Fecha"]  
4 )
```

3.7. Definir cadenas que representan valores faltantes

```
1 df = pd.read_csv(  
2     "datos.csv",  
3     na_values=["", "NA", "N/A", "NULL", "null", "-", "Sin dato"]  
4 )
```

3.8. Decimales y separadores de miles

```
1 # Ejemplo: 1.234,56  
2  
3 df = pd.read_csv(  
4     "datos.csv",  
5     decimal=",",  
6     thousands="."  
7 )
```

3.9. Omitir filas iniciales

```
1 df = pd.read_csv("datos.csv", skiprows=2)
```

3.10. Leer solamente las primeras filas

```
1 df = pd.read_csv("datos.csv", nrows=1000)
```

3.11. Leer archivos grandes por bloques

```
1 for bloque in pd.read_csv("datos_grandes.csv", chunksize=100_000):  
2     print(bloque.shape)
```

3.12. Leer Excel

```
1 df = pd.read_excel("datos.xlsx")
```

Seleccionar hoja:

```
1 df = pd.read_excel("datos.xlsx", sheet_name="Hoja1")
```

Leer varias hojas:

```
1 hojas = pd.read_excel("datos.xlsx", sheet_name=None)  
2  
3 # Acceder a una hoja concreta  
4  
5 df = hojas["Hoja1"]
```

3.13. Leer JSON

```
1 df = pd.read_json("datos.json")
```

3.14. Leer Parquet

```
1 df = pd.read_parquet("datos.parquet")
```

3.15. Leer datos desde el portapapeles

Útil cuando se copia una tabla desde Excel o una página web.

```
1 df = pd.read_clipboard()
```

4. Inspección inicial del DataFrame

4.1. Mostrar el DataFrame

```
1 print(df)
```

En Jupyter basta con escribir:

```
1 df
```

4.2. Primeras filas

```
1 df.head()           # 5 primeras filas
2
3 df.head(10)         # 10 primeras filas
```

4.3. Últimas filas

```
1 df.tail()
2 df.tail(10)
```

4.4. Muestra aleatoria

```
1 df.sample(5)
```

Muestra reproducible:

```
1 df.sample(5, random_state=42)
```

Muestra porcentual:

```
1 df.sample(frac=0.10, random_state=42)
```

4.5. Número de filas y columnas

```
1 df.shape
2
3 filas, columnas = df.shape
4 print("Filas:", filas)
5 print("Columnas:", columnas)
```

4.6. Número total de elementos

```
1 df.size
```

4.7. Nombres de columnas

```
1 df.columns
2
3 list(df.columns)
```

4.8. Índice

```
1 df.index
```

4.9. Tipos de datos

```
1 df.dtypes
```

Tipo de una columna concreta:

```
1 df["Edad"].dtype
```

4.10. Resumen estructural

```
1 df.info()
```

4.11. Estadística descriptiva rápida

Solo columnas numéricas:

```
1 df.describe()
```

Todas las columnas:

```
1 df.describe(include="all")
```

Solo columnas de texto/catóricas:

```
1 df.describe(include=["object", "string", "category"])
```

4.12. Cantidad de valores no nulos por columna

```
1 df.count()
```

4.13. Memoria utilizada

```
1 df.memory_usage()
2
3 df.memory_usage(deep=True)
4
5 df.memory_usage(deep=True).sum()
```

5. Selección de columnas y filas

5.1. Seleccionar una columna

```
1 edad = df["Edad"]
```

5.2. Seleccionar varias columnas

```
1 sub = df[["Nombre", "Edad", "Ciudad"]]
```